

Guía Paso a Paso para realizar un EDA

El principal propósito del análisis exploratorio es tener una idea completa de cómo son nuestros datos, antes de decidir qué técnica de Ciencia de Datos o de Machine Learning usaremos. Pero también permite plantearse o replantearse preguntas, hipótesis creativas y obtener nuevo conocimiento. Como es de imaginar, es un proceso cíclico, completamente desestructurado y se aplica desde que logramos obtener nuestras estructuras de datos hasta la evaluación de los resultados de los modelos construidos.

En el mundo real los datos no son ideales, debemos organizarlos, entender su contenido, entender cuáles son las variables más relevantes y cómo se relacionan unas con otras, comenzar a ver algunos patrones, determinar qué hacer con los datos faltantes y con los datos atípicos, y finalmente extraer conclusiones acerca de todo este análisis.

Es, en resumen, una forma de entender, visualizar y extraer información relevante del set de datos para poder decidir cuál será la ruta o técnica más adecuada para su posterior procesamiento. También implica acciones de modificación y preprocesamiento para adaptar los datos a una forma apropiada (reduciendo dimensionalidad, cambiando unidades de medida, cambiando tipología de variables, creando características analizables., etc.)

EDA en 7 pasos, y contando ...:

1. Tener una idea general de nuestro dataset
2. Tener clara la pregunta que queremos responder
3. Definir los tipos de datos que tenemos
4. Elegir el tipo de estadística descriptiva
5. Visualizar los datos
6. Analizar las posibles interacciones entre las variables del dataset
7. Extraer algunas conclusiones de todo este análisis.

Pasos 1 y 2:

Lo primero es lo primero: ¿Cuáles son nuestros datos? Cantidad de filas, cantidad de columnas, qué representan, en qué unidad de medida. Podemos traducir los nombres de columnas o aclararlos. Un *sample()* acá no viene nada mal. ¿Qué significado tienen los valores? Ej: si en la columna de color aparece el valor **B** o **no color** o **bla** significan **blanco**?

Luego:

La pregunta que queremos responder, al menos la primera que se nos ocurre. Pueden ir apareciendo otras. Es importante entender que la columna con las respuestas que queremos obtener debe estar completa. De lo contrario no podremos entrenar ni probar adecuadamente nuestro modelo.

Paso 3:

Comenzamos a analizar en detalle el dataset. Debemos definir a qué categoría de dato pertenece cada variable o característica (columna). Hay dos grandes grupos: los datos numéricos y los datos categóricos.

Los datos numéricos pueden ser discretos (como por ejemplo la edad) o continuos (como por ejemplo la altura o el precio que pagó por un boleto, etc.).

Los datos categóricos pueden ser nominales, binarios u ordinales. Los nominales se usan para etiquetar el dato pero no pueden ser ordenados ni medidos, como por ejemplo la profesión de una persona: médico, periodista, etc.

Los datos binarios indican una de dos posibles categorías, como por ejemplo “sobreviviente” o “no sobreviviente”.

Y finalmente están los datos ordinales que, como su nombre lo indica, corresponden al orden en el que vienen representados los datos, como por ejemplo nivel educativo: 1, 2 o 3.

Paso 4:

El cuarto paso es iniciar con la descripción estadística. Dependerá del tipo de datos que tengamos en cada variable. La idea es analizar cada variable (columna) por separado. Esto se conoce como Análisis Univariado.

Para esto usamos dos grandes tipos de medidas: las de tendencia central (media, mediana, moda) y las de variabilidad (varianza, desviación estándar, rango intercuartílico).

Si los datos son de tipo categórico lo lógico es usar moda y frecuencias normalizadas (relativas al total). Si son numéricos se pueden emplear media, mediana y las medidas de dispersión. A veces, a efectos de simplificar el análisis, conviene convertir datos continuos en discretos definiendo intervalos de pertenencia.

RECORDAR NUNCA MODIFICAR LAS COLUMNAS ORIGINALES, SINO REPRODUCIRLA EN OTRA COLUMNA Y APLICAR ALLÍ LOS CAMBIOS!!!

Paso 5:

La limitación de las medidas centrales y de las de variabilidad es que son sólo un número, que nos puede dar apenas una idea general del comportamiento de nuestros datos. Hay mucho gato encerrado entre los números, y es más sencillo verlos usando gráficos. Así que el quinto paso del análisis exploratorio es visualizar la distribución de los datos para tener una idea más sintética, y al mismo tiempo, abarcativa de su comportamiento.

Para datos continuos y discretos podemos calcular y dibujar el histograma, que se obtiene tras organizar los datos en diferentes subgrupos (o bins) y realizar el conteo del número de datos en cada uno. Con el histograma podemos verificar si la distribución es normal (es decir que tiene forma como de campana simétrica) o si está sesgada (una campana asimétrica).

La desventaja del histograma es que no permite ver en detalle los valores atípicos, porque quedarán enmascarados al incluirlos en un bin, o simplemente se pierden si en el gráfico hay demasiados bins. La alternativa en este caso, o cuando la distribución es sesgada, es usar los diagramas de caja o boxplots, que también se pueden usar para datos discretos y continuos. Un dispersograma (si no hay demasiados datos) puede ayudar a identificar valores atípicos (outliers) y típicos (inliers).

En un boxplot se representa el rango intercuartílico en una caja y los extremos como líneas (bigotes), que representan los percentiles 25 y 75. Las barras superior e inferior corresponden a los percentiles 75 y 25, mientras que la línea en medio de la caja es la mediana. Los bigotes suelen medir aproximadamente 1.5 del rango intercuartílico. Si hay outliers, estos se representan con puntos o círculos en el valor preciso de cada uno.

Si los datos son categóricos podemos usar los gráficos de barras, representando el conteo de ocurrencias en cada categoría o el porcentaje que estas representan del total de datos.

Al detectar outliers debe analizarse uno por uno qué hacer con ellos. Considerarlos, eliminarlos, colocar como faltante ese dato...

Paso 6:

Ahora resultará interesante ver si existe algún tipo de interacción entre dos o más variables, usando lo que se conoce como el Análisis Bivariado, o su vuelta de rosca: Análisis Multivariado.

Análisis Bivariado

El análisis bivariado consiste en comparar pares de variables. Las comparaciones las podemos realizar usando medidas estadísticas como el índice de correlación entre estas dos variables, donde un valor cercano a 1 nos indica una relación lineal, uno cercano a -1 una relación lineal inversa, y un valor cercano a cero indica que no hay correlación lineal entre los datos.

También podemos usar gráficos para realizar estas comparaciones (recordemos que se construyen a partir de los valores estadísticos...)

Tendremos 3 situaciones diferentes; para cada una de ellas convendrá más un tipo de gráfico.

Comparar dos variables numéricas. Podemos usar una gráfica de dispersión, donde cada punto es representado por un caso (fila), y podemos verificar si existe alguna tendencia lineal: es decir si el aumento de una variable genera un aumento o disminución de la otra.

Comparar una variable numérica con una variable categórica y usar por ejemplo un boxplot para cada valor categórico.

Comparar dos variables categóricas usando gráficos de barras apiladas.

Análisis Multivariado

Por otra parte, en el análisis multivariado comparamos simultáneamente todos los posibles pares de variables para intentar encontrar algún tipo de relación.

Para cada comparación calculamos el índice de correlación entre diferentes pares de variables y dibujamos los resultados en una matriz de correlación. En la diagonal principal de esta matriz tendremos valores iguales a 1, porque estamos comparando una variable consigo misma. Pero lo que nos interesa es lo que está por fuera de esta diagonal. Podemos analizar en detalle diferentes pares de variables para ver si hay relaciones más relevantes que otras.

Gráficamente están buenos los mapas de calor o las matrices de dispersión.

Paso 7:

Y la última fase de este análisis exploratorio consiste en extraer las conclusiones más importantes del análisis que hemos venido realizando. La forma más práctica es escribirlas, como frases muy cortas.

Esto nos servirá para identificar por ejemplo qué variables están correlacionadas, o cuáles de ellas resultan de pronto más relevantes. Esto es fundamental para las etapas que vendrán más adelante en el proyecto, como el pre-procesamiento de los datos, la extracción de características o el desarrollo mismo del modelo en el caso del Machine Learning.